

共享-RF 多用户混合预编码中的 优化问题与 SVD / GMD 的高低 SNR 分析

1 最终优化目标

考虑下行多用户共享-RF 混合预编码。基站有 N_t 根天线、 N_{RF} 条 RF 链路，服务 K 个用户；每个用户有 N_r 根接收天线、承载 d 条数据流。总流数为

$$D = Kd. \quad (1)$$

发射信号为

$$\mathbf{x} = \mathbf{F}_{\text{RF}} \mathbf{F}_{\text{BB}} \mathbf{s}, \quad (2)$$

其中

$$\mathbf{F}_{\text{RF}} \in \mathbb{C}^{N_t \times N_{\text{RF}}}, \quad \mathbf{F}_{\text{BB}} = [\mathbf{F}_1, \dots, \mathbf{F}_K], \quad \mathbf{F}_k \in \mathbb{C}^{N_{\text{RF}} \times d}. \quad (3)$$

用户 k 的接收信号为

$$\mathbf{y}_k = \mathbf{H}_k \mathbf{F}_{\text{RF}} \mathbf{F}_{\text{BB}} \mathbf{s} + \mathbf{n}_k, \quad \mathbf{n}_k \sim \mathcal{CN}(\mathbf{0}, \mathbf{I}_{N_r}). \quad (4)$$

最终真正想最大化的是当前接收机口径下的总速率

$$\max_{\mathbf{F}_{\text{RF}}, \mathbf{F}_{\text{BB}}} \sum_{k=1}^K R_k^{(\text{rx})}, \quad (5)$$

其中约束为

$$|[\mathbf{F}_{\text{RF}}]_{ij}| = \frac{1}{\sqrt{N_t}}, \quad \forall i, j, \quad (6)$$

$$\|\mathbf{F}_{\text{RF}} \mathbf{F}_{\text{BB}}\|_F^2 = D. \quad (7)$$

也就是说，优化目标是最大化总速率，优化约束是 constant-modulus 模拟前端约束和总发射功率约束。

2 非完美 CSI 下的 full-covariance LMMSE

为了同时覆盖 perfect CSI 与非完美 CSI 两种情形，下面区分

$$\mathbf{H}_k^{(\text{tx})} \quad \text{和} \quad \mathbf{H}_k^{(\text{rx})}. \quad (8)$$

其中 $\mathbf{H}_k^{(\text{tx})}$ 表示发端设计 precoder 时可见的 CSI， $\mathbf{H}_k^{(\text{rx})}$ 表示最终接收端评估时的真实信道。

在 perfect CSI 下,

$$\mathbf{H}_k^{(\text{tx})} = \mathbf{H}_k^{(\text{rx})} = \mathbf{H}_k. \quad (9)$$

在 mmse_fullcov 非完美 CSI 下,

$$\mathbf{H}_k^{(\text{tx})} = \widehat{\mathbf{H}}_k, \quad \mathbf{H}_k^{(\text{rx})} = \mathbf{H}_k. \quad (10)$$

2.1 LMMSE 观测模型

当前代码先离线估计单用户信道向量的均值与 full covariance。令

$$\mathbf{h} = \text{vec}(\mathbf{H}) \in \mathbb{C}^{N_r N_t \times 1}, \quad (11)$$

则先验写成

$$\mathbf{h} \sim \mathcal{CN}(\bar{\mathbf{h}}, \mathbf{C}_h). \quad (12)$$

pilot 采用 repeated-identity 结构。若 pilot 长度为 L , 则

$$\mathbf{P} = \underbrace{[\mathbf{I}_{N_t}, \mathbf{I}_{N_t}, \dots, \mathbf{I}_{N_t}]}_{L/N_t \text{ 次}} \in \mathbb{C}^{N_t \times L}. \quad (13)$$

对用户 k , pilot 观测为

$$\mathbf{Y}_k = \mathbf{H}_k \mathbf{P} + \mathbf{N}_k, \quad [\mathbf{N}_k]_{ij} \sim \mathcal{CN}(0, \sigma_p^2). \quad (14)$$

向量化后可写成标准线性高斯模型

$$\mathbf{y}_k = \mathbf{A} \mathbf{h}_k + \mathbf{n}_k, \quad \mathbf{A} = \mathbf{P}^T \otimes \mathbf{I}_{N_r}. \quad (15)$$

2.2 full-covariance LMMSE 估计式

在上述先验和观测模型下, 创新协方差为

$$\boldsymbol{\Sigma}_{\text{innov}} = \mathbf{A} \mathbf{C}_h \mathbf{A}^H + \sigma_p^2 \mathbf{I}. \quad (16)$$

LMMSE 不是直接写结果, 而是从“最小化真实信道与估计信道之间的均方误差”出发。先设一个仿射估计器

$$\widehat{\mathbf{h}}_k = \mathbf{b} + \mathbf{G} \mathbf{y}_k. \quad (17)$$

其优化目标是

$$\min_{\mathbf{b}, \mathbf{G}} \mathbb{E} \left[\left\| \mathbf{h}_k - \widehat{\mathbf{h}}_k \right\|_2^2 \right]. \quad (18)$$

利用先验均值, 把变量中心化。记

$$\tilde{\mathbf{h}}_k = \mathbf{h}_k - \bar{\mathbf{h}}, \quad \tilde{\mathbf{y}}_k = \mathbf{y}_k - \mathbf{A} \bar{\mathbf{h}}. \quad (19)$$

则观测模型可改写成

$$\tilde{\mathbf{y}}_k = \mathbf{A} \tilde{\mathbf{h}}_k + \mathbf{n}_k. \quad (20)$$

此时估计器可以写成

$$\hat{\mathbf{h}}_k = \bar{\mathbf{h}} + \mathbf{G}\tilde{\mathbf{y}}_k, \quad (21)$$

于是 MSE 变成

$$J(\mathbf{G}) = \mathbb{E} \left[\left\| \tilde{\mathbf{h}}_k - \mathbf{G}\tilde{\mathbf{y}}_k \right\|_2^2 \right]. \quad (22)$$

把平方项展开，可写成

$$J(\mathbf{G}) = \text{tr}(\mathbf{C}_h) - \text{tr}(\mathbf{G}\mathbf{A}\mathbf{C}_h) - \text{tr}(\mathbf{C}_h\mathbf{A}^H\mathbf{G}^H) + \text{tr}(\mathbf{G}\Sigma_{\text{innov}}\mathbf{G}^H). \quad (23)$$

对 $\mathbf{G}$ 求极小，可得正规方程

$$\mathbf{G}\Sigma_{\text{innov}} = \mathbf{C}_h\mathbf{A}^H, \quad (24)$$

因此最优解就是

$$\mathbf{G}_{\text{LMMSE}} = \mathbf{C}_h\mathbf{A}^H\Sigma_{\text{innov}}^{-1}. \quad (25)$$

于是后验均值，也就是代码里实际使用的发端 CSI 估计，为

$$\hat{\mathbf{h}}_k = \bar{\mathbf{h}} + \mathbf{G}_{\text{LMMSE}}(\mathbf{y}_k - \mathbf{A}\bar{\mathbf{h}}). \quad (26)$$

这条式子可以直接理解成

估计值 = 先验均值 + 增益 × 观测创新。

其中

$$\bar{\mathbf{h}} \quad (27)$$

是离线统计出来的先验均值；

$$\mathbf{y}_k \quad (28)$$

是当前这一次导频发送后得到的带噪观测；

$$\mathbf{A}\bar{\mathbf{h}} \quad (29)$$

表示“如果当前信道就等于先验均值，那么理论上应该看到的导频观测”；因此

$$\mathbf{y}_k - \mathbf{A}\bar{\mathbf{h}} \quad (30)$$

就是当前观测相对于先验平均情况的创新。LMMSE 增益

$$\mathbf{G}_{\text{LMMSE}} \quad (31)$$

决定了我们该把这部分创新相信多少。

所以当前代码里的逻辑是：

1. 先离线用很多个 CDL-A 信道样本统计出先验均值 $\bar{\mathbf{h}}$ 和协方差 $\mathbf{C}_h$ ；
2. 再对当前未知真实信道发导频，得到带噪观测 $\mathbf{y}_k$ ；
3. 最后用上面的 LMMSE 更新式，把当前观测对先验均值做修正，得到 $\hat{\mathbf{h}}_k$ 。

再 reshape 回矩阵形式得到

$$\widehat{\mathbf{H}}_k = \text{unvec}(\hat{\mathbf{h}}_k). \quad (32)$$

因此在 mmse_fullcov 模式下，后面的优化、结构化初始化与基线排序，都是基于 $\widehat{\mathbf{H}}_k$ 来设计；但最终接收机性能仍然在真实信道 $\mathbf{H}_k$ 上汇报。

3 为什么不能直接优化这个目标

困难在于：

1. 接收机使用的是 hard-SIC / THP-aware 的有限星座打分，目标函数不光滑；
2. 共享模拟前端与数字块强耦合，问题高度非凸；
3. 模拟前端还带有 element-wise constant-modulus 约束。

因此实际做法不是直接对上式求解，而是把它改写成可微 surrogate 优化问题。

3.1 原始硬判决目标是什么

当前线性分支在接收端采用的是 hard-SIC。把检测坐标系中的等效信道记为上三角矩阵 $\mathbf{R}_k$ ，则某个样本上的接收信号可写成

$$\tilde{\mathbf{y}}_k = \sqrt{\gamma} \mathbf{R}_k \mathbf{s}_k + \tilde{\mathbf{n}}_k. \quad (33)$$

hard-SIC 从最后一层往前递推。若第 i 层之后的已判决符号为 $\hat{s}_{k,j}$ ，则当前层残差为

$$\tilde{z}_{k,i}^{(\text{hard})} = [\tilde{\mathbf{y}}_k]_i - \sum_{j=i+1}^d \sqrt{\gamma} [\mathbf{R}_k]_{ij} \hat{s}_{k,j}. \quad (34)$$

随后做硬判决：

$$\hat{s}_{k,i} = \arg \min_{a \in \mathcal{X}} \left| \tilde{z}_{k,i}^{(\text{hard})} - \sqrt{\gamma} [\mathbf{R}_k]_{ii} a \right|^2. \quad (35)$$

也就是说，所谓“hard”的含义，不是把目标函数简单写成分类准确率，而是：后续层干扰消除时使用的是硬符号判决值 $\hat{s}_{k,i}$ ，而不是 soft 平均值。

在此基础上，第 q 个 bit 的 LLR 仍然按当前残差做 bit-wise log-sum-exp：

$$L_{k,i,q}^{(\text{hard})} = \log \sum_{a \in \mathcal{X}_{q,1}} \exp \left(- \left| \tilde{z}_{k,i}^{(\text{hard})} - \sqrt{\gamma} [\mathbf{R}_k]_{ii} a \right|^2 \right) - \log \sum_{a \in \mathcal{X}_{q,0}} \exp \left(- \left| \tilde{z}_{k,i}^{(\text{hard})} - \sqrt{\gamma} [\mathbf{R}_k]_{ii} a \right|^2 \right). \quad (36)$$

于是当前接收机口径下的 hard-SIC bit-wise GMI 可以写成

$$R_{k,\text{hard}} = dQ - \frac{1}{N_{\text{MC}}} \sum_{n=1}^{N_{\text{MC}}} \sum_{i=1}^d \sum_{q=1}^Q \frac{1}{\ln 2} \log \left(1 + e^{-(2B_{k,i,q}^{(n)} - 1) L_{k,i,q}^{(\text{hard}), (n)}} \right). \quad (37)$$

因此，最原始的优化目标其实更接近

$$\max_{\mathbf{F}_{\text{RF}}, \mathbf{F}_{\text{BB}}} \sum_{k=1}^K R_{k,\text{hard}}, \quad (38)$$

只不过这个目标里嵌着硬判决递推 $\hat{s}_{k,i}$ ，所以它对优化变量既不平滑，也不利于梯度优化。

4 实际可微优化目标

4.1 约束吸收到变量参数化里

把模拟前端直接参数化成相位矩阵

$$\mathbf{F}_{\text{RF}}(\boldsymbol{\Theta}) = \frac{1}{\sqrt{N_t}} e^{j\boldsymbol{\Theta}}, \quad \boldsymbol{\Theta} \in \mathbb{R}^{N_t \times N_{\text{RF}}}, \quad (39)$$

这样 constant-modulus 约束被自动满足。

数字变量记为 $\{\mathbf{C}_k\}_{k=1}^K$ 。给定 $\boldsymbol{\Theta}$ 后，定义有效信道

$$\widetilde{\mathbf{H}}_k(\boldsymbol{\Theta}) = \mathbf{H}_k \mathbf{F}_{\text{RF}}(\boldsymbol{\Theta}). \quad (40)$$

把其他用户有效信道堆叠为 $\widetilde{\mathbf{H}}_{-k}(\boldsymbol{\Theta})$ ，定义投影矩阵

$$\boldsymbol{\Pi}_k(\boldsymbol{\Theta}) = \mathbf{I}_{N_{\text{RF}}} - \widetilde{\mathbf{H}}_{-k}(\boldsymbol{\Theta})^\dagger \widetilde{\mathbf{H}}_{-k}(\boldsymbol{\Theta}), \quad (41)$$

于是数字块写成

$$\widetilde{\mathbf{F}}_k = \boldsymbol{\Pi}_k(\boldsymbol{\Theta}) \mathbf{C}_k. \quad (42)$$

把所有用户块拼接为

$$\widetilde{\mathbf{F}}_{\text{BB}} = [\widetilde{\mathbf{F}}_1, \dots, \widetilde{\mathbf{F}}_K], \quad (43)$$

再做总功率归一化

$$\alpha(\boldsymbol{\Theta}, \{\mathbf{C}_k\}) = \sqrt{\frac{D}{\|\mathbf{F}_{\text{RF}}(\boldsymbol{\Theta}) \widetilde{\mathbf{F}}_{\text{BB}}\|_F^2}}, \quad (44)$$

$$\mathbf{F}_{\text{BB}}(\boldsymbol{\Theta}, \{\mathbf{C}_k\}) = \alpha(\boldsymbol{\Theta}, \{\mathbf{C}_k\}) \widetilde{\mathbf{F}}_{\text{BB}}. \quad (45)$$

所以现在真正优化的变量就是

$$\boldsymbol{\Theta} \quad \text{和} \quad \{\mathbf{C}_k\}_{k=1}^K. \quad (46)$$

4.2 可微速率 surrogate

训练时不用最终的 hard-SIC 指标，而用 soft-SIC surrogate。记当前检测坐标系中的接收残差为

$$\widetilde{z}_{k,i} = [\widetilde{\mathbf{y}}_k]_i - \sum_{j=i+1}^d \sqrt{\gamma} [\mathbf{R}_k]_{ij} \bar{s}_{k,j}, \quad (47)$$

对星座点 $a \in \mathcal{X}$ 定义距离

$$D_{k,i}(a) = |\widetilde{z}_{k,i} - \sqrt{\gamma} [\mathbf{R}_k]_{ii} a|^2. \quad (48)$$

给定温度 $T > 0$ ，soft posterior 权重为

$$w_{k,i}(a; T) = \frac{e^{-D_{k,i}(a)/T}}{\sum_{b \in \mathcal{X}} e^{-D_{k,i}(b)/T}}. \quad (49)$$

对应的软符号估计为

$$\bar{s}_{k,i} = \sum_{a \in \mathcal{X}} w_{k,i}(a; T) a. \quad (50)$$

对第 q 个 bit, soft LLR 写成

$$L_{k,i,q}^{(\text{soft})} = T \left[\log \sum_{a \in \mathcal{X}_{q,1}} e^{-D_{k,i}(a)/T} - \log \sum_{a \in \mathcal{X}_{q,0}} e^{-D_{k,i}(a)/T} \right]. \quad (51)$$

bit-wise log-loss 为

$$\ell_{k,i,q} = \frac{1}{\ln 2} \log \left(1 + e^{-(2B_{k,i,q}-1)L_{k,i,q}^{(\text{soft})}} \right). \quad (52)$$

于是每用户 surrogate 速率定义为

$$\hat{R}_{k,\text{soft}} = dQ - \frac{1}{N_{\text{MC}}} \sum_{n=1}^{N_{\text{MC}}} \sum_{i=1}^d \sum_{q=1}^Q \ell_{k,i,q}^{(n)}. \quad (53)$$

4.3 干扰泄漏惩罚

为避免单纯追求 surrogate 速率而放大跨用户干扰, 定义

$$P_{\text{des}} = \sum_{k=1}^K \left\| \widetilde{\mathbf{H}}_k(\boldsymbol{\Theta}) \widetilde{\mathbf{F}}_k \right\|_F^2, \quad (54)$$

$$P_{\text{off}} = \sum_{k=1}^K \sum_{t \neq k} \left\| \widetilde{\mathbf{H}}_k(\boldsymbol{\Theta}) \widetilde{\mathbf{F}}_t \right\|_F^2, \quad (55)$$

$$\eta_{\text{soft}} = \frac{P_{\text{off}}}{P_{\text{des}}}. \quad (56)$$

4.4 最终实际优化目标

于是训练时真正求解的是

$$\min_{\boldsymbol{\Theta}, \{C_k\}} \mathcal{L}(\boldsymbol{\Theta}, \{C_k\}) = - \sum_{k=1}^K \hat{R}_{k,\text{soft}} + \lambda_{\text{int}} \eta_{\text{soft}}. \quad (57)$$

这就是整套联合优化最核心的数学式。

5 优化算法

由于 $\boldsymbol{\Theta}$ 与 $\{C_k\}$ 强耦合, 代码采用 alternating optimization:

1. 固定 $\boldsymbol{\Theta}$, 对 $\{C_k\}$ 做若干步 Adam;
2. 固定 $\{C_k\}$, 对 $\boldsymbol{\Theta}$ 做若干步 Adam;
3. 每次更新相位后执行

$$\boldsymbol{\Theta} \leftarrow (\boldsymbol{\Theta} + \pi) \bmod 2\pi - \pi, \quad (58)$$

把相位压回 $[-\pi, \pi)$;

4. 外层温度按

$$T_1, \dots, T_L = \text{geospace}(T_{\text{init}}, T_{\text{final}}) \quad (59)$$

逐步退火。

温度退火的作用是让训练从平滑 surrogate 逐渐逼近硬判决结构。因为当 $T \rightarrow 0^+$ 时，

$$T \log \sum_a e^{-D(a)/T} \rightarrow -\min_a D(a), \quad (60)$$

所以 soft-SIC 会退化到 max-log / hard-SIC 的极限形式。

6 SIC 与 THP 的简单示例

这里用一个 2×2 上三角示例说明：为什么当前 SIC 这条线不做发端 modulo，而 THP 这条线需要 modulo。

6.1 SIC：干扰在接收端消除，所以发端不需要 modulo

设等效上三角信道为

$$\mathbf{R} = \begin{bmatrix} 2 & 1 \\ 0 & 2 \end{bmatrix}, \quad \mathbf{s} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}. \quad (61)$$

忽略噪声时，

$$\mathbf{y} = \mathbf{R}\mathbf{s} = \begin{bmatrix} 3 \\ 2 \end{bmatrix}. \quad (62)$$

这条链路里发射端发的仍然是原始符号 $\mathbf{s}$ ，没有任何递推，因此也没有 modulo。SIC 全部发生在接收端：

$$\hat{s}_2 = y_2/2 = 1, \quad (63)$$

$$\hat{s}_1 = (y_1 - 1 \cdot \hat{s}_2)/2 = (3 - 1)/2 = 1. \quad (64)$$

所以当前 SIC 的本质是线性发射 + 接收端串行消除。既然发射端没有做递推预消除，自然也不需要 modulo。

6.2 THP：干扰在发射端预消除，所以需要 modulo

若把同样的上三角耦合搬到发射端处理，就进入 THP。设归一化上三角为

$$\mathbf{B}_1 = \begin{bmatrix} 1 & 1.5 \\ 0 & 1 \end{bmatrix}, \quad \mathbf{s} = \begin{bmatrix} 1 \\ -1 \end{bmatrix}. \quad (65)$$

THP 递推为

$$\tilde{s}_2 = \mathcal{M}_\tau(-1) = -1, \quad (66)$$

$$\tilde{s}_1 = \mathcal{M}_\tau(1 - 1.5 \cdot (-1)) = \mathcal{M}_\tau(2.5). \quad (67)$$

如果不做 modulo，第一层发射符号会因为递推而变大；modulo 的作用就是把它折回基本区间。例如当 $\tau = 2$ 时，

$$\tilde{s}_1 = \mathcal{M}_2(2.5) = 0.5. \quad (68)$$

这说明 THP 的本质是发射端递推预消除 + modulo 控制幅度。

结论 所以当前代码里并不是“发射端用 SIC 但没做 modulo”，而是：

1. ‘SIC’ 分支本来就是接收端算法，发射端仍发原始 QAM 符号；
2. 只有当干扰递推被搬到发射端时，它才变成 ‘THP’，这时才需要 modulo。

7 Perfect CSI 下 SVD 与 GMD 的高低 SNR 证明

下面只保留这一个理论比较问题。设 perfect CSI 成立，即

$$\mathbf{H}_k^{(\text{tx})} = \mathbf{H}_k^{(\text{rx})} = \mathbf{H}_k. \quad (69)$$

记某用户 reduced channel 的前 d 个奇异值为

$$\sigma_{k,1} \geq \cdots \geq \sigma_{k,d} > 0, \quad (70)$$

并记几何平均为

$$\delta_k = \left(\prod_{i=1}^d \sigma_{k,i} \right)^{1/d}. \quad (71)$$

7.1 低 SNR：SVD 通常强于 GMD

低 SNR 下，SVD 与 GMD 的一阶信号能量项相同，因为 GMD 只是对 SVD 基做右酉旋转，不改变 Frobenius 能量：

$$\|\bar{\Sigma}_k \mathbf{\Omega}_k\|_F^2 = \|\bar{\Sigma}_k\|_F^2. \quad (72)$$

若把当前 hard-SIC / bit-wise GMI 下的每用户速率写成

$$R_k^{(x)}(\gamma) = a_k \gamma - \xi_k^{(x)} \gamma^2 + o(\gamma^2), \quad x \in \{\text{svd}, \text{gmd}\}, \quad (73)$$

则一阶系数 a_k 对两者相同，差异来自二阶项。

这里的核心原因是：

1. SVD 对应的等效块是对角结构，不引入额外的用户内上三角串扰；
2. GMD 虽然把对角拉平，但其上三角一般非零；
3. 在低 SNR 下，这些额外串扰首先体现为二阶损失。

因此通常有

$$\xi_k^{(\text{gmd})} \geq \xi_k^{(\text{svd})}, \quad (74)$$

从而得到

$$R_k^{(\text{svd})}(\gamma) \geq R_k^{(\text{gmd})}(\gamma), \quad \gamma \downarrow 0. \quad (75)$$

所以低 SNR 下“SVD 强于 GMD”的结论，来自低阶展开与二阶损失分析，不是 AM-GM 不等式。

7.2 高 SNR 过渡区：GMD 可能反超

高 SNR 过渡区里，主导因素变成最弱层门限。对 SVD，

$$g_{k,\min}^{(\text{svd})} = \sigma_{k,d}. \quad (76)$$

对 GMD，所有层都被拉到几何平均量级，因此

$$g_{k,\min}^{(\text{gmd})} \approx \delta_k. \quad (77)$$

这时才用到 AM-GM。不等式给出

$$\delta_k^2 = \left(\prod_{i=1}^d \sigma_{k,i}^2 \right)^{1/d} \geq \sigma_{k,d}^2. \quad (78)$$

如果把“所有流都稳定解码”近似成最弱层跨过某个门限 γ_{th} ，则

$$\gamma_{\text{th},k}^{(\text{svd})} \approx \frac{\gamma_{\text{th}}}{\sigma_{k,d}^2}, \quad \gamma_{\text{th},k}^{(\text{gmd})} \approx \frac{\gamma_{\text{th}}}{\delta_k^2}. \quad (79)$$

由于 $\delta_k^2 \geq \sigma_{k,d}^2$ ，因此

$$\gamma_{\text{th},k}^{(\text{gmd})} \leq \gamma_{\text{th},k}^{(\text{svd})}. \quad (80)$$

于是就可能出现一个高 SNR 过渡区间，使得 GMD 比 SVD 更早跨过最弱层门限，从而出现

$$R_k^{(\text{gmd})}(\gamma) > R_k^{(\text{svd})}(\gamma) \quad (81)$$

的现象。再往更高 SNR 走，有限星座速率都逐渐饱和，二者差距又会缩小。

结论

低 SNR 下 SVD 通常强于 GMD；高 SNR 过渡区里，GMD 可能由于最弱流被拉平而反超；AM-GM 只用于解释后者。

8 与高斯信息参考对比

下面给出两张参考图。黑色虚线表示 AO Gaussian Info 曲线，其余彩色曲线仍然是当前有限星座、当前接收机口径下的性能。




图 1: Perfect CSI 下各方法与 AO Gaussian Info 的对比。展示区间为 0 dB 到 50 dB，纵轴截到 50 bits/s/Hz。




图 2: 非完美 CSI (mmse_fullcov) 下各方法与 AO Gaussian Info 的对比。